

第十九届“挑战杯”全国大学生课外学术 科技作品竞赛“揭榜挂帅”专项赛 成果汇报书

推报学校名称：中国矿业大学

参加竞榜的选题发榜单位：中国联合网络通信集团有限公司

参加竞榜的选题名称：“基于大模型的多模态风险内容识别技术
研究”比赛方案

作品具体名称：基于大模型的多模态诈骗内容识别检测系统

申报者姓名：张向宏 沈玉东 杨佩锦 曾翔宇 熊德志 刘家豪 谢圣民

摘要

随着通信技术和数字技术的快速发展与普及，诈骗、谣言等风险内容随之增加，成为社会管理和网络空间治理的新挑战。基于大模型的多模态诈骗内容识别系统是一种集成多种数据类型（文本、音频、视频）进行诈骗风险识别的系统。该系统利用大语言模型智能体技术和多模态数据处理技术，旨在提高对诈骗行为的识别和预警能力。在识别诈骗短信功能部分，该系统使用了 DeepfakeChat 大语言模型进行诈骗短信识别，该模型通过对 ChatGLM3-6b 进行了 LoRA+DoRA 微调技术，使用了包括 30000 多条诈骗短信和 14000 多条非诈骗短信，训练使得模型能够更准确地识别和理解短信中的诈骗信息。对于识别诈骗电话的能力，该系统的音频处理模块通过模型调用 Function Calling 技术，执行诈骗音频分析和音频转文字的模型。系统能够分析音频内容，识别其中的诈骗行为，并将音频转换为文字形式，综合结果返回给大语言模型进行处理。对于视频伪造人脸识别的功能，该系统的视频处理模块通过模型调用 Function Calling 技术，执行分析伪造人脸的模型。用户上传的视频文件会被系统分析，识别其中可能存在的伪造人脸和欺诈行为，分析结果返回给大语言模型进行回答。通过整合文本、音频和视频三种数据类型的分析结果，多模态诈骗内容识别系统能够提供全面和准确的诈骗风险识别和预警服务，保护用户免受各种诈骗行为的侵害。该系统在识别准确率、召回率以及处理速度方面进行了精心优化与高效设计，通过细致入微的技术调整与策略部署，成功在实验和演示阶段取得了令人瞩目的优异表现。

关键词：智能体，大语言模型，多模态大数据，诈骗风险识别

目录

摘要.....	2
1. 引言.....	5
1.1 背景与意义.....	5
1.2 研究目标.....	7
2. 相关技术介绍.....	8
2.1 LLM 大语言模型.....	8
2.2 前端 Vue3 架构.....	9
2.3 后端 FastAPI 架构.....	10
3. 方案亮点与创新点.....	11
4. 系统设计.....	13
4.1 系统架构.....	13
4.2 诈骗短信识别模块设计.....	16
4.2.1 数据集介绍.....	16
4.2.2 DoRA 微调方法.....	17
4.2.3 文本识别智能体 Prompt 封装流程.....	19
4.2.4 涉诈行为风险点摘要关键词云设计.....	19
4.3 诈骗电话识别模块设计.....	21
4.3.1 深度音频检测.....	21
4.3.2 音频识别技术.....	25
4.3.3 音频识别智能体 Prompt 封装流程.....	27
4.4 视频伪造识别模块设计.....	29
4.4.1 模型训练流程.....	30
4.4.2 人脸伪造风险点摘要热力图设计.....	31
4.4.3 视频伪造识别智能体 Prompt 封装流程.....	33
5 技术实现.....	35
5.1 数据收集与预处理.....	35
5.2 模型选择与训练.....	40
5.3 系统性能分析.....	42
6. 成果展示.....	50
6.1 文本智能体.....	50
6.2 音频智能体.....	52
6.3 视频智能体.....	54
6.4 智能分析模块.....	56
6.5 涉诈风险态势分析平台.....	57
7. 实用性和应用前景.....	58

作品评估标准索引表

评选标准与分值	评选角度	具体划分页码
1、作品完整性 (40)	独立研发并完成基于大模型的多模态风险内容识别系统，功能完整可用，为 40 分。如未完成，按照完成比例给予评定，最多不超过 20 分。	1、诈骗短信识别设计 13-19 页 2、诈骗电话检测设计 21-28 页 3、视频伪造识别设计 29-34 页
2、系统性能 (30)	根据系统识别准确率、召回率，处理速度和效率，提供的风险点摘要质量进行打分，综合评定 0-30 分。	1、系统性能分析 42-49 页 2、风险点摘要展示案例 50-57 页
3、技术创新性 (20)	考量作品在系统设计、数据处理、策略开发、大模型技术应用等方面的创新点，综合评定 0-20 分。	1、系统设计图 13 页 2、数据处理 35-39 页 3、策略开发 11 页 4、大模型技术应用 11 页
4、实用性和应用前景 (10)	根据系统在实际场景中的应用价值，系统部署和维护的成本效益比进行打分，综合评定 0-10 分。	1、实用性 58 页 2、应用前景 59 页

1. 引言

1.1 背景与意义

随着互联网和移动通信技术的迅猛发展，网络诈骗和电信诈骗案件层出不穷，给社会带来了巨大的经济损失和安全隐患。诈骗手段日益复杂和多样化，涉及到短信、语音电话、视频等多种媒介，传统的单一防范手段已经难以应对这些新型诈骗行为。构建一个能够综合利用多种数据源，识别多种诈骗模式的智能系统，显得尤为重要。

数字经济时代，以“Deepfake”为代表的深度换脸技术更加智能化和高度真实化，尤其是大模型的快速发展使得深度伪造更加逼真，场景更加复杂，技术变种更快更多。当前，深度伪造技术被非法用于经济、政治、社会等领域，形成严重危害，获评“未来两年全球十大风险”之首，深度伪造检测面临更大挑战与更高要求。

根据相关资料，防伪大模型已经成为大模型时代深度防伪新机遇。在思维链（Chain of Thought）作用下，防伪大模型拥有前所未有的编码能力，可以通过编码进行概念延伸和推理，充分掌握图片细节所蕴含的内在信息；同时，由于 Scaling Law 规模效应，防伪大模型的鉴伪能力随伪造数据的增加而线性增加，这一趋势目前仍未看到瓶颈。防伪大模型将复杂问题转变为数据驱动的简单问题，避免了传统专家模型的复杂设计思路，极大提升了防伪效果。

在当下的网络环境，发展深度防御伪造大模型已经刻不容缓，大模型时代深度防伪检测面临的挑战也是要解决突破的难点。具体如下：

a) 深度伪造成效更加逼真：

国务院发展研究中心国际技术经济研究所唐乾琛提出，当下，以 Midjourney、DALL-E、Stable Diffusion 等为代表的专业生成式人工智能模型，能够通过用户输入的图像和文字生成以假乱真的图像，达到与现实难以区分的效果。随着深度学习技术与 AIGC 在视频和图像生成领域的广泛应用，当前生成视频质量越来越贴近真实视频且以更低成本普及。以 ChatGPT 4.0 与 DALL·E 为代表的面向视频内容生成大语言模型的出现使得人脸生成发展迈上新台阶，Sora 和 ChatGPT-4o 的接续发布无疑验证了通过大规模数据训练 AI 模型能够创造更为逼

真的理解现实世界物理规律形象的可能性。凭借扩散模型通过训练神经网络来逆转添加高斯噪声带来的纯噪声，即从纯噪声中合成数据直到产生干净样本的机制，使得人脸视频防伪检测技术难以捕捉视频伪造线索。

b) 深度伪造场景更加复杂：

深度伪造技术在色情、欺诈、合成语音等典型场景存在较多应用与风险，特别是开源代码的普及，使得这一技术的泛在普适性特征更加显著，面临着低门槛扩散化的风险。近年来，虚假内容泛滥成灾、花样迭出，衍生出篡改选举、传播假新闻和诬陷造谣等新的应用场景并呈现平民化趋势，应用形式更加复杂多样。浙江大学副教授冯尊磊提出“真实场景下，人脸视频防伪检测工作易受环境因素干扰。例如，光照条件的改变可能使人脸的阴影和高光区域发生变化，使得人脸看起来更暗或更亮。摄像机角度的改变可能导致人脸的形状和特征发生畸变，使得人脸看起来扭曲或失真。此外，背景复杂性的变化也可能导致人脸的边缘模糊或与背景融合，使得人脸看起来不清晰或不成比例。以上这些因素都会对人脸视频的真实性和可信度产生影响，增加人脸视频防伪检测工作识别和检测的困难度”。

c) 深度伪造技术变种更快更多：

近十年，深伪技术日趋成熟，生成式 AI 横空出世后，扩散模型（Diffusion Model）解决了 VAEs 的后验分布对齐问题、GANs 的不稳定性、EBMs 的计算量大和 NFs 的网络约束问题，推动 Deepfake 数量不断增加，并逐渐从单一模态向跨模态或多模态演变。东南大学法学院研究员王禄生提出，深度伪造技术本质上是一种“无监督学习”，具有极强的自我适应性，具有快速演化性等特征，这一特征将使得视频造假能力呈现指数级跃升。能力的提升伴随着成本的下降，地下交易市场中攻击道具交易已颇具规模，通常 200 元就能买到一次定点攻击服务。现阶段针对单一人脸视频防伪检测数据集的防伪检测技术的防伪效果虽然较为理想，但在跨数据集防伪效果实验中的泛化性能仍表现出明显的不足。同时，在现实场景下，由于人脸视频伪造方法未知，难以获得伪造方法的具体类型。

多模态风险诈骗系统正是在这样的背景下应运而生的。它结合了

先进的人工智能技术和多模态数据处理技术，能够对文本、音频和视频等多种形式的诈骗信息进行识别和分析，实现了以下几点意义：

1) 提升诈骗识别准确率：

通过对 ChatGLM3-6b 模型进行 DoRA 微调，基于大量诈骗短信和非诈骗短信数据，系统能够更精确地识别短信中的诈骗信息，提高了文本诈骗识别的准确率。

2) 多模态数据融合分析：

通过引入音频和视频处理模块，系统不仅能分析文字信息，还能识别语音和视频中的诈骗行为。音频模块能够将语音内容转换为文字，并通过语音分析模型识别诈骗，视频模块则能识别视频中的伪造人脸等诈骗特征，实现了多模态数据的融合分析，增强了诈骗识别的全面性。

3) 社会影响：

在当前网络诈骗日益猖獗的背景下，多模态风险诈骗系统的研发和应用不仅能够保护个人和企业的财产安全，还能提升社会整体安全感，具有显著的社会效益。综上所述，多模态风险诈骗系统的开发和应用，具有重要的技术创新意义和广泛的社会影响，能够有效应对日益复杂的诈骗行为，保护用户的安全，助力构建更为安全的网络环境。

1.2 研究目标

多模态风险诈骗系统的研究目标是构建一个能够综合利用多种数据源，识别多种诈骗模式的智能系统，提升对各类诈骗行为的识别和预警能力。具体目标包括：

- **多模态数据融合**

开发基于大模型的多模态风险内容识别系统，能够有效整合文本、音频和视频三种数据源，充分利用多模态数据的互补性，提高诈骗识别的全面性和准确性。

- **文本诈骗识别智能体**

通过对 ChatGLM3-6b 模型进行 DoRA 微调，基于 30000 多条诈骗短信和 14000 多条非诈骗短信数据，并且封装好诈骗识别的案例 Prompt，使模型能够高效、精准地识别短信中的诈骗行为。

- **音频诈骗识别智能体**

通过识别用户输入，根据对话内容，自动识别 Function Calling，调用工具诈骗音频分析模型和音频转文字模型，确保系统能够准确分析和识别音频中的诈骗行为，并将分析结果与文本数据进行整合。

- **视频诈骗识别智能体**

通过识别用户输入，根据对话内容，自动识别 Function Calling，调用工具分析伪造人脸的模型，识别用户上传的视频中的伪造人脸和其他欺诈行为，并将结果与其他数据源的分析结果整合。

- **系统性能优化**

优化系统性能，确保在处理多模态数据时的高效性和准确性，提升系统的实用性和用户体验。

- **应用推广与影响**

推广多模态风险诈骗系统的应用，提升社会对智能防诈骗系统的认识，增强公众防范诈骗的意识和能力，减少因诈骗造成的经济损失和安全隐患。

通过实现上述目标，多模态风险诈骗系统将能够提供一个全面、高效、智能的诈骗风险识别解决方案，保护用户的安全，助力构建更为安全的网络环境。

2. 相关技术介绍

2.1 LLM 大语言模型

大语言模型（Large Language Models, LLMs）是基于深度学习技术，特别是 Transformer 架构，训练得到的大规模自然语言处理模型。这些模型在处理各种语言任务，如文本生成、翻译、问答、情感分析等方面表现出色。大语言模型的训练涉及海量文本数据，通过学习这些数据中的语言模式和上下文关系，模型能够生成具有上下文连贯性的文本，并理解和回答复杂的语言问题。

该项目采用的是 ChatGLM3-6B 模型。ChatGLM3-6B 是由清华大学 KEG 实验室和智谱 AI 联合研发的一个大型中文对话生成模型，基于 GLM（General Language Model）架构，具有 60 亿个参数。该模型专为中文环境设计，旨在提供高效、自然的对话生成能力。相比之前的版本，ChatGLM3-6B 在模型规模、训练数据和性能上有显著提

升。并且具有在 10B 以下的基础模型中最强的性能。

ChatGLM3-6B 采用了改进的 GLM 架构，这是一种基于 Transformer 的神经网络模型，结合了自回归和自编码方法，提升了生成质量和训练效率。与传统的语言模型不同，GLM 架构在处理文本生成任务时更具灵活性和高效性。

为了更好地处理中文语言特有的挑战，ChatGLM3-6B 在设计和训练过程中进行了多方面优化。模型使用了大量的中文文本数据进行预训练，涵盖了新闻、百科、社交媒体等多种类型的文本。通过这种大规模预训练，模型能够在广泛的领域内具备良好的理解和生成能力。

ChatGLM3-6B 的一个关键技术细节是混合注意力机制（Hybrid Attention Mechanism），这种机制结合了全局和局部注意力，提升了模型对长文本的处理能力。此外，为了应对大规模训练数据带来的计算压力，ChatGLM3-6B 采用了分块训练（Chunked Training）策略，将训练数据分成多个小块，逐块训练，减小了单次计算的内存需求。

ChatGLM3-6B 在多个应用场景中展示了广泛的应用前景。在智能客服方面，ChatGLM3-6B 能够理解客户的问题，并提供准确和即时的回答，提升客户服务质量和效率。在内容创作领域，利用 ChatGLM3-6B，可以进行高质量的文本生成，如写作辅助、自动新闻生成等，节省人力成本。

此外，ChatGLM3-6B 还可用于语言教育，提供实时对话练习和纠错功能，帮助学习者提高语言能力。在社交媒体平台上，ChatGLM3-6B 能够生成个性化的内容和回复，增强用户互动体验。

作为一款先进的中文对话生成模型，ChatGLM3-6B 凭借其创新的架构设计和强大的生成能力，在多个应用领域展示了广泛的应用前景。随着技术的不断进步和优化，ChatGLM3-6B 将在更广泛的场景中发挥重要作用，为人工智能技术的发展和应用提供新的动力。

2.2 前端 Vue3 架构

Vue3 架构是基于 Vue.js 的最新版本，于 2020 年正式发布。Vue3 在性能、易用性、代码组织等方面进行了全面升级，为前端开发者带来了更加高效、灵活的开发体验。

Vue 3 引入了 Composition API，这是一种基于函数的 API，用于

逻辑复用和组件代码的组织。与传统的 Options API 相比, Composition API 提供了更强的灵活性和可组合性, 使得代码更易于维护和测试。通过函数形式来管理组件的状态和生命周期, 使开发者可以更加灵活地组织和复用代码。

随着前端技术的不断发展, Vue.js 也在不断演进。Vue 3 的发布带来了性能的提升、开发体验的改进和更强大的功能。未来, Vue.js 将继续围绕性能优化、开发体验提升和生态系统扩展进行发展。随着更多开发者和企业的采用, Vue.js 将在前端开发领域发挥越来越重要的作用。

2.3 后端 FastAPI 架构

FastAPI 是一个现代的、快速、高性能的 Web 框架, 用于构建基于 Python 的 API。它基于标准的 Python 类型提示 (type hints) 进行声明, 从而实现更快的开发、简化代码和自动生成文档。FastAPI 的核心是依赖于 Starlette 用于 Web 框架部分和 Pydantic 用于数据验证部分。

FastAPI 最显著的特性之一是其性能。它使用 Python 的类型提示, 在性能上可以与 Node.js 和 Go 等高性能语言相媲美。FastAPI 通过 ASGI (Asynchronous Server Gateway Interface) 实现异步支持, 使其能够处理大量并发请求。

FastAPI 自动生成交互式 API 文档, 这些文档基于 OpenAPI 和 JSON Schema。开发者只需在代码中添加少量注释, FastAPI 就能生成类似 Swagger UI 和 ReDoc 的文档界面。这使得 API 的调试和测试变得非常直观和简单。

随着对高性能 Web 框架需求的增加, FastAPI 的受欢迎程度也在不断上升。其简洁的语法、自动化的文档生成和强大的数据验证功能, 使得越来越多的开发者和企业选择 FastAPI 来构建他们的 API 服务。未来, FastAPI 预计会进一步优化性能, 扩展其生态系统, 并提供更多的内置功能, 以满足不断增长的市场需求。

3. 方案亮点与创新点

- 高精度的风险识别引擎

本系统依托的 DeepfakeChat 大语言模型，是在强大的基座模型 ChatGLM3-6B 基础上，通过我们精心构建的包含 30,000+ 诈骗短信与 14,000+ 非诈骗短信的专属数据集进行深度监督微调而诞生的。这一创新训练策略显著提升了模型对诈骗信息的敏锐洞察力，实现了对诈骗短信高达 98.5% 的识别准确率，为防范诈骗筑起了一道坚实的防线。

- 跨语言分析能力

DeepfakeChat 模型在训练过程中融入了英文语料，这一创举打破了语言壁垒，使得系统不仅能够精准识别中文诈骗短信，还能有效分析英文诈骗信息，并自动提取风险词汇，为全球用户提供了无国界的安全防护。

- 多模态数据深度融合技术

在音频智能处理领域，本系统实现了多模态数据的无缝融合与综合分析。我们不仅直接对音频文件进行深度风险解析，还巧妙地将语音对话转化为文本，充分利用大语言模型的语言理解优势，对对话内容同样进行诈骗风险评估。这种跨模态的协同分析策略，极大地丰富了风险识别的维度，进一步提升了识别精度。

- 用户友好的交互界面

系统借鉴了业界领先的 AI 交互平台设计理念，如百度文心一言、OpenAI ChatGPT 等，为用户提供了直观、便捷的交互体验。用户可以随时与内置的大语言模型进行自然流畅的对话，模型则能迅速响应，提供准确且及时的反馈，极大地增强了用户的使用满意度和信赖感。

- 风险态势可视化大屏

本系统创新性地引入了风险态势图功能，通过对全国范围内诈骗风险数据的统计与分析，实现了诈骗风险态势的可视化呈现。这一功能不仅标注了当前社会诈骗风险的高发区域，还以直观的图表形式展示了整体风险趋势及地域分布情况，为相关部门制定针对性的防范措施提供了强有力的数据支持。

- 多角度风险点摘要

本项目通过多角度、多模态的方式识别和展示伪造内容的特征。

具体而言，在文本分析模块，我们设计并实现了涉诈高风险词云展示功能，直观呈现文本中频繁出现的诈骗关键词，为识别者提供一目了然的风险预警。对于音频数据，我们引入了梅尔频率倒谱系数(MFCC)分析及音频波形图展示，精准捕捉音频中的伪造特征，如变声、拼接等痕迹，进一步增强了音频诈骗内容的识别能力。此外，在人脸视频模块，我们创新性地应用人脸高风险区域热力图，通过热力图高亮显示视频帧中可能涉及伪造或异常的人脸区域，为视频诈骗检测提供直观且科学的依据。这一系列创新点与亮点，共同构成了本项目在多模态诈骗内容识别领域的独特优势。

4. 系统设计

4.1 系统架构

基于大模型的多模态诈骗内容识别系统的系统架构如下图 4-1 所示，分为用户层、业务层、大模型能力层和数据层四个部分。每个层次在系统中承担不同的功能，共同构建了一个完整的多模态诈骗风险识别系统。



图 4-1 系统架构图

1. 用户层

用户层包括个人用户和运营商企业用户，主要是系统的终端用户，

他们通过系统获取防诈骗服务。

个人用户：包括普通消费者和个人用户，他们希望通过系统识别并防范诈骗信息。

运营商企业用户：包括通信运营商、金融机构等企业用户，他们希望通过系统提高对诈骗行为的防范能力，保护客户安全。

2. 输出层

结果分析报告：针对用户上传的多模态数据以及问题，生成详细的诈骗风险评估报告。包含文本、音频、视频分析结果。

风险点摘要展示：提取并突出显示检测到的主要风险点,包括可疑文本片段、音频异常和视频伪造迹象。使用直观的图形界面,如热图或词云,清晰标记风险区域,便于用户快速定位和评估潜在威胁。

涉诈风险态势分析平台：大屏展示界面作为系统的核心视觉呈现，集成了丰富的图表与数据，为安全专家及管理人员提供直观、全面的诈骗风险态势分析

3. 业务层

业务层是系统的核心功能层，包括多种诈骗识别和分析模块：

诈骗文本分析：利用大语言模型对文本数据进行分析，识别诈骗短信和邮件等文本内容。

音频伪造分析：分析语音电话、录音等音频数据，识别其中的伪造和欺诈内容。

视频人脸伪造识别：分析视频数据，识别视频中的伪造人脸和欺诈行为。

音频涉诈内容分析：进一步分析音频内容，提取与诈骗相关的特征和信息。

风险态势分析：综合多模态数据，评估整体诈骗风险态势，提供实时预警。

多模态风险识别：整合文本、音频、视频分析结果，进行综合识别和评估，提高整体防诈骗能力。

4. 大模型能力层

大模型能力层提供系统所需的核心技术和算法支持：

大模型训练微调：针对具体应用场景对大语言模型进行训练和微

调，以提高模型的识别精度和适应性。

要素抽取：从多模态数据中提取关键特征和要素，供后续分析使用。

智能对话：提供智能对话接口，支持用户与系统之间的自然语言交互。

意图识别：识别用户输入的意图，帮助系统做出相应的处理和反馈。

5. 预处理层

预处理层是整个多模态诈骗内容识别系统的关键部分，它负责将收集到的原始数据进行清洗、标准化和特征提取，以便后续的大模型处理层能够高效、准确地进行分析。下面详细介绍预处理层的各个步骤：

文本清洗与标准化：去除无关字符,纠正拼写错误,统一格式如全部小写。进行分词、词形还原,处理多语言文本。这一步骤将原始文本转换为结构化形式,为后续分析和模型处理做好准备,有助于识别隐藏的可疑内容。

音频特征提取：将音频信号转换为特征向量,包括时域特征(如能量、过零率)和频域特征(如 MFCC、谱质心)。提取音高、谐波等信息,用于分析说话人情绪、识别合成声音,以及检测背景噪音中的异常。

视频帧提取与图像处理：从视频中提取关键帧,进行大小调整、亮度标准化、去噪和颜色空间转换。执行人脸检测、对齐和背景分离等操作,为深度学习模型准备标准化输入,有助于检测 DeepFake 等伪造内容。

6. 数据层

数据层是系统的数据基础，提供各种数据的存储和管理：

文本数据：存储和管理系统所需的各种文本数据，包括真实短信和诈骗短信。

音频数据：存储和管理系统所需的音频数据，包括真实电话录音和诈骗录音。

视频数据：存储和管理系统所需的视频数据，包括真实视频和伪造视频。

通过上述六个层次的协同工作，多模态风险诈骗系统能够高效、准确地进行多模态数据的综合分析与处理，为用户提供全面、可靠的诈骗风险识别与预警服务。

4.2 诈骗短信识别模块设计

识别诈骗短信是一项复杂且具有挑战性的任务。随着技术的发展，诈骗者的手段也在不断更新和升级，使得传统的识别方法逐渐失效。以下是识别诈骗短信所面临的一些主要挑战：

短信内容多样性：诈骗短信的内容形式多种多样，从虚假的银行通知、伪装的快递信息到冒充亲友的求助短信。诈骗者常常通过模仿真实的服务信息来迷惑接收者，使得仅通过内容识别变得困难。

语言和语境变化：诈骗短信可以使用不同的语言和地方方言，这增加了识别的复杂性。此外，短信的语境也可以根据接收者的个人信息进行定制，使得基于固定规则的识别方法失效。

信息量有限：短信的字符数通常有限，这使得诈骗者倾向于使用简洁、模糊的语言表达。这种信息量的限制增加了识别诈骗短信的难度，因为无法通过长文本的上下文来判断信息的真实性。

为了应对这些挑战，该模块使用了 DeepfakeChat 模型，该模型是由经过 DoRA 微调的大语言模型 ChatGLM3-6b 训练而来的，用以提高对诈骗短信的识别准确性和处理效率。

4.2.1 数据集介绍




图 4-2 数据集类型分布图

微调数据由 3 万条诈骗短信和 1.4 万条非诈骗短信构成。分布图

如图 4-2 所示，诈骗短信中包括以下几种。

- ◆ 赌博 (Gambling): 赌博消息是数据集中最常见的类型之一。
- ◆ 伪造身份证和发票 (Fake ID and invoice): 包括伪造身份证和发票相关的垃圾短信。
- ◆ 政治宣传 (Political propaganda): 涉及政治内容的宣传性垃圾短信。
- ◆ 非法推广 (Illegal Promotion): 包括以下子类别：伴游服务 (Escort service)、网络服务 (Network service)、零售 (Retail)、贷款服务 (Loan service)、房地产 (Real estate)
- ◆ 欺诈 (Fraud): 包括以下子类别：银行网络钓鱼 (Phishing (Bank))、其他网络钓鱼 (Phishing (Others))、金融欺诈 (Financial fraud)、广告 (Advertisement): 包括合法的广告推广消息，但在法律下被视为非法的推广活动。
- ◆ 其他 (Others): 包括无法归入上述任何类别的其他类型的垃圾短信。

4.2.2 DoRA 微调方法

DoRA 微调是由 LoRA 演变而来，具体的原理图如下图 4-3 所示。




图 4-3 LoRA、DyLoRA、DoRA 的原理图

1. LoRA

LoRA (Low-Rank Adaptation, 低秩适应) 是最广为人知的重参数化技术之一。对于一个给定的预训练权重矩阵 $\mathbf{W}_0 \in \mathbf{R}^{d \times k}$, LoRA 引入两个可训练的权重矩阵, $\mathbf{W}_{up} \in \mathbf{R}^{d \times r}$ 和 $\mathbf{W}_{down} \in \mathbf{R}^{r \times k}$, 其中秩 r 远小于 $\min(d, k)$, 并行操作于 $\mathbf{W}_0$ 上。令 $\mathbf{h}_{in}$ 表示输入。在正常情况下, 通过 $\mathbf{W}_0$ 的输出是 $\mathbf{h}_{out} = \mathbf{W}_0 \mathbf{h}_{in}$ 。而 LoRA 通过引入一个增量更新

$\Delta\mathbf{W}$ 来修改该输出，该增量更新包含任务特定的知识，具体公式如下所示：

$$\mathbf{h}_{\text{out}} = \mathbf{W}_0\mathbf{h}_{\text{in}} + \frac{\alpha}{r}\Delta\mathbf{W}\mathbf{h}_{\text{in}} = \mathbf{W}_0\mathbf{h}_{\text{in}} + \frac{\alpha}{r}\mathbf{W}_{\text{up}}\mathbf{W}_{\text{down}}\mathbf{h}_{\text{in}}$$

其中 α 是一个缩放因子。在训练开始时， $\mathbf{W}_{\text{down}}$ 使用随机高斯分布初始化，而 $\mathbf{W}_{\text{up}}$ 初始化为零，确保 $\Delta\mathbf{W}$ 初始为零。完成微调后，LoRA的自适应权重与预训练的主干权重无缝集成，确保在推理期间不增加额外的负担。

2. DyLoRA

DyLoRA（动态 LoRA）是在 LoRA 基础上的一种改进方法，专注于解决 LoRA 训练过程中如何选择合适秩的问题。DyLoRA 的目标是通过在一系列秩范围内训练 LoRA 模块，确保在不同条件下都能找到最佳秩，以实现更高效、更准确的微调。

具体原理：在 DyLoRA 中，不是固定一个秩 r 进行训练，而是设定一个秩范围 $r_{\min} \leq r \leq r_{\max}$ 。在这个范围内，DyLoRA 会根据训练过程中的实际表现动态调整秩的大小。这种动态调整使得模型在不同阶段能够自动选择最适合的秩，以优化微调效果。

具体公式：在 DyLoRA 中，基本的重参数化公式与 LoRA 类似，但在秩的选择上采用动态调整：

$$\mathbf{h}_{\text{out}} = \mathbf{W}_0\mathbf{h}_{\text{in}} + \frac{\alpha}{r(t)}\Delta\mathbf{W}\mathbf{h}_{\text{in}} = \mathbf{W}_0\mathbf{h}_{\text{in}} + \frac{\alpha}{r(t)}\mathbf{W}_{\text{up}}\mathbf{W}_{\text{down}}\mathbf{h}_{\text{in}}$$

其中 $r(t)$ 表示在训练第 t 个时刻动态选择的秩大小。

DyLoRA 通过这种动态调整机制，实现了在训练过程中根据实际需求灵活调整参数配置，从而在保证模型性能的同时，提高了训练和推理的效率。

3. DoRA

DoRA（方向性 LoRA）是一种改进的 LoRA 技术，专注于在权重矩阵的特定方向上进行低秩近似。与传统 LoRA 不同，DoRA 通过分解权重矩阵，分别考虑权重变化的方向和大小，从而实现更有效的参数微调。

具体原理：将权重矩阵 $\mathbf{W}_0$ 分解为方向矩阵 $\mathbf{V}$ 和大小向量 $\mathbf{m}$ ：

$$\mathbf{W}_0 = \mathbf{V} \cdot \mathbf{m}$$

其中， $\mathbf{V}$ 是一个方向矩阵，表示权重变化的方向， $\mathbf{m}$ 是一个大小向量，表示权重变化的大小。

在微调过程中，DoRA 对权重矩阵进行低秩近似，通过调整大小向量 $\mathbf{m}$ 的值来更新权重矩阵：

$$\Delta \mathbf{W} = \mathbf{V} \cdot \Delta \mathbf{m}$$

其中， $\Delta \mathbf{m}$ 表示权重变化的大小调整。

具体公式：在 DoRA 中，基本的重参数化公式表示为：

$$\mathbf{h}_{\text{out}} = \mathbf{W}_0 \mathbf{h}_{\text{in}} + \frac{\alpha}{|\mathbf{V} + \Delta \mathbf{V}|^c} \Delta \mathbf{W} \mathbf{h}_{\text{in}} = \mathbf{W}_0 \mathbf{h}_{\text{in}} + \frac{\alpha}{|\mathbf{V} + \Delta \mathbf{V}|^c} \mathbf{V} \cdot \Delta \mathbf{m} \cdot \mathbf{h}_{\text{in}}$$

$\mathbf{W}_0$ 表示预训练模型的权重矩阵， $\mathbf{V}$ 表示权重变化的方向矩阵， $\Delta \mathbf{m}$ 表示权重变化的大小向量， α 是一个缩放因子， $|\mathbf{V} + \Delta \mathbf{V}|^c$ 是用于归一化的范数， $\Delta \mathbf{V}$ 表示权重变化方向的调整。

DoRA 通过分解权重矩阵，分别控制权重变化的方向和大小，实现了更精确和高效的参数微调。这种方法不仅提高了训练和推理的效率，还在多个任务中展示了优异的性能表现。

4.2.3 文本识别智能体 Prompt 封装流程

文本部分构造的智能体 Prompt 的设计需要构造该智能体的思维链，文本智能体主要由模型本身的能力和我们微调后的权重相结合构成的，所以正常来说思维链也比较简单，因为是 ChatGLM3-6b 微调后的模型，所以思维链的格式也是一样的，具体如下所示：

<|system|>

你是一个诈骗分析小助手,请分析用户给你的诈骗短信并给出风险最高的五个词。

<|user|>

用户输入短信内容并提问是否是诈骗短信

<|assistant|>

回答是否是诈骗短信，并且给出风险词

4.2.4 涉诈行为风险点摘要关键词云设计

词云部分思维链设计就相对来说比较复杂了，里面涉及了前端数据的传递以及模型工具的调用。具体的思维链如下所示：

<|system|>

你是一个诈骗分析小助手,请分析用户给你的诈骗短信并给出风险最高的五个词。

<|user|>

用户输入短信内容并提问是否是诈骗短信

<|assistant|>

思考应该做什么

<|assistant|>调用工具名称(该模块为 `text_function`)

```
... python
```

```
tool_call(调用工具的参数)
```

```
...
```

<|observation|>

工具返回结果

将工具返回的结果送回给前端，返回结果为 tools 中 `text_function` 设置的变量 `Number1-Number5`，分别表示的是诈骗概率最高的五个风险词语。具体的实现流程如下图 4-4 所示：




图 4-4 词云实现流程图

4.3 诈骗电话识别模块设计

4.3.1 深度音频检测

多模态风险诈骗识别系统中的深度伪造（Deepfake）音频的检测成为了一个重要的研究领域。深度伪造音频是通过人工智能技术合成或修改的音频，听起来非常真实，但实际是伪造的。这种技术可能被用于诈骗、诽谤等非法活动，因此，开发有效的检测技术对于维护社会安全和个人权益至关重要。深度伪造音频的检测面临着多重挑战：

- 1) **高逼真度**：深度伪造技术能够生成几乎无法通过人耳辨别真伪的音频。
- 2) **技术多样性**：深度伪造音频可以通过多种技术生成，包括文本到语音（TTS）、语音合成和语音转换等。
- 3) **数据集限制**：目前用于深度伪造音频检测的数据集相对有限，且多样性不足。

为了应对上述挑战，本研究提出了一种基于机器学习和深度学习的方法来检测深度伪造音频。我们使用了 Mel 频率倒谱系数(MFCC)技术来从音频中提取特征，并利用多种机器学习模型进行分类。具体的处理流程如图 4-5 所示




图 4-5 深度音频检测模型设计图

梅尔频率倒谱系数（Mel-Frequency Cepstral Coefficients，简称 MFCC）是一种广泛用于音频处理和语音识别的特征提取方法。MFCC 通过模拟人类听觉系统来捕捉音频信号的特征。它在 Windows 系统中的转换流程如下图 4-6 所示




图 4-6 MFCC 特征转换图

1. A/D 转换

A/D 转换对音频剪辑进行取样，将内容数字化，即将模拟信号转换为离散空间。经常使用 8 kHz 或 16 kHz 的采样频率。如图 4-7 为具体转换流程。




图 4-7 A/D 转换图

2. 预加重 (Pre-emphasis)

预加重是对音频信号进行高频增强，通常通过一个高通滤波器来实现。公式如下：

$$y(t) = x(t) - \alpha x(t - 1)$$

其中， $y(t)$ 是预加重后的信号， $x(t)$ 是原始信号， α 是预加重系数（通常取值为 0.95 或 0.97）。

3. 分帧 (Framing)

将音频信号分成多个短时间帧，每个帧通常持续 20 到 40 毫秒，以确保在每个帧内信号是平稳的。假设音频信号的采样率为 16 kHz，每帧长度为 25 毫秒（400 个样本），帧移为 10 毫秒（160 个样本）。如图 4-8 所示为分帧操作：




图 4-8 分帧流程图

4. 加窗（Windowing）

对每个帧应用一个窗口函数（通常使用 Hamming 窗），以减少频谱泄漏。Hamming 窗的公式为：

Hamming($\alpha = 0.46164$) or *Hanning*($\alpha = 0.5$) window

$$w[n] = (1 - \alpha) - \alpha \cos\left(\frac{2\pi n}{L - 1}\right) \quad L: \text{window width}$$

其中，L 是窗口长度，n 是帧内的样本索引。

5. 离散傅里叶变换（DFT）

对每个加窗后的帧进行离散傅里叶变换，将时间域信号转换到频域，得到频谱。公式如下：

$$X(k) = \sum_{n=0}^{N-1} x(n)e^{-j\frac{2\pi kn}{N}}$$

其中，X(k)是频域信号，x(n)是时间域信号，N 是帧长，k 是频率索引。

6. 梅尔滤波器组（Mel Filter Bank）

设备测量与我们的听觉感知并不相同。对于人类来说，感知的响

度根据频率变化。此外，感知频率解析度随着频率增加而降低。即人类对高频较不敏感。如图 4-9 显示了梅尔刻度如何将测量频率映射到我们在频率解析度上的感知。所有这些映射都是非线性的。

在特征提取中，我们使用三角形带通滤波器来转换频率信息，以模仿人类的感知。




图 4-9 梅尔滤波映射器

首先，我们对 DFT 的输出进行平方。这反映了每个频率处的语音功率 ($x[k]^2$)，我们称之为 DFT 功率谱。我们使用这些三角形梅尔刻度滤波器组将其变换为梅尔刻度功率谱。每个梅尔刻度功率谱插槽的输出代表其覆盖的一些频带的能量。这种映射称为 Mel Binning。公式为：

$$Y_t[m] = \sum_{k=1}^N W_m[k] |X_t[k]|^2$$

其中, k : DFT 编号 ($1, \dots, N$) , m : 梅尔滤波器组编号 ($1, \dots, M$)

7. 对数变换 (Logarithm)

对每个滤波器输出的能量取对数，以模拟人耳的对数感知。公式为：

$$\log E(m) = \log(E(m))$$

其中， $\log E(m)$ 是第 m 个滤波器的对数能量。

8. 逆离散傅里叶变换 (IDFT)

对对数梅尔能量谱进行逆离散傅里叶变换 (IDFT)，得到倒谱系

数。通常只保留前 13 个倒谱系数（MFCCs），公式如下：

$$C(n) = \sum_{m=0}^{M-1} \log E(m) \cos\left(\frac{\pi n(2m+1)}{2M}\right)$$

其中， $C(n)$ 是第 n 个 MFCC， M 是梅尔滤波器的数量。

9. 动态特征（Dynamic features）

为了捕捉信号的动态变化，可以计算 MFCC 的一阶和二阶差分，即 MFCC 的变化率和加速度。公式如下：

$$\Delta C(n) = C(n+t) - C(n-t)$$

其中， $\Delta C(n)$ 是第 n 个 MFCC 的一阶差分， t 是时间间隔。

4.3.2 音频识别技术

我们在音频风险检测智能体中加入了音频识别的模块，即将输入的音频转成文字加入音频识别的 Prompt 中，这样即使对方的声音不是伪造的也可以根据通话内容进行诈骗风险识别。因此我们引入使用了 Whisper 模型。

Whisper 是 OpenAI 开发的一种先进的声音识别与处理技术。通过深度学习算法，Whisper 能够准确捕捉声音中的细微变化，进而实现高质量的声音识别、分析与合成。该技术具有较高的识别准确率、广泛的适用场景以及强大的扩展性，因此在多个领域都有广泛应用。

OpenAI 通过从网络上收集了 68 万小时的多语言（98 种语言）和多任务监督数据对 Whisper 进行了训练。OpenAI 认为使用这样一个庞大而多样的数据集，可以提高对口音、背景噪音和技术术语的识别能力。除了可以用于语音识别，Whisper 还能实现多种语言的转录，以及将这些语言翻译成英语。OpenAI 开放模型和推理代码，希望开发者可以将 Whisper 作为建立有用的应用程序和进一步研究语音处理技术的基础。如图 4-10 为原理图。




图 4-10 Whisper 原理图

Whisper 架构是一种简单的端到端方法，作为编码器-解码器 Transformer 实现。输入音频被分割成 30 秒的块，转换为对数梅尔频谱图，然后传递到编码器中。解码器经过训练以预测相应的文本标题，并与特殊标记混合，这些标记指示单个模型执行语言识别、短语级时间戳、多语言语音转录和英语语音翻译等任务。

但是考虑到响应时间的问题，因为 Whisper 在进行语音转文字的过程中需要的时间还是很长的，需要几分钟甚至更久，于是我们在项目中使用了 Whisper 的优化版本 Fast-Whisper。

Fast Whisper 是对 OpenAI 的 Whisper 模型的一个优化版本，旨在提高音频转录和语音识别任务的速度和效率。它通过多种技术手段对原始模型进行了改进，使得在保持相似识别准确率的同时，能够显著提升处理速度和降低资源消耗。仔细说来，Fast whisper 是使用 CTranslate2 对 OpenAI 的 Whisper 模型的重新实现，CTranslate2 是一个用于 Transformer 模型的快速推理引擎。

在使用更少内存的情况下，该实现比 Whisper 在相同精度下快 4

倍。同时在 CPU 和 GPU 上进行 8 位量化，可以进一步提高算法效率。

它主要的核心优化有以下几个方面：

- ◆ 剪枝：通过减少模型中的参数数量（通常是去除那些对模型性能影响较小的参数），从而减少模型的复杂性和运行时内存需求。
- ◆ 量化：将模型的浮点运算转换为整数运算，这通常会显著减少模型大小和提升推理速度，特别是在支持整数运算的硬件上。
- ◆ 硬件优化：Fast Whisper 针对特定的硬件架构（如 GPU 和 TPU）进行了优化，以更高效地利用这些硬件的并行处理能力。
- ◆ 更高效的解码器：使用更高效的解码策略，比如更小的 beam size 或更快的贪心算法，来减少在生成预测时所需的计算量。

通过上述技术改进，Fast Whisper 在进行语音到文本转录时的速度更快，同时减少了模型的计算需求和内存占用。这使得它更适合实时或接近实时的应用场景，并且能够在资源受限的设备上运行，如移动设备和嵌入式系统。因此在音频诈骗识别智能体中的运用显得尤为重要。

4.3.3 音频识别智能体 Prompt 封装流程

首先和文本模块一样，需要设计出音频识别智能体的思维链，音频识别部分的思维链有需要涉及到工具的调用，在音频部分涉及到了两个其他模型的调用，一个是诈骗音频识别，一个是语音内容识别。首先是诈骗音频识别的思维链如下所示：

<|user|>

用户上传音频文件，并询问是否是诈骗音频

<|assistant|>

思考应该做什么

<|assistant|>调用工具名称(该模块为 `audio_function`)

``` python

`tool_call`(调用工具的参数)

```

<|observation|>

工具返回结果

<|assistant|>

(获取音频是否为诈骗音频)返回给用户结果

诈骗音频识别部分的调用流程如下图 4-11 所示：




图 4-11 音频识别基础流程图

语音内容识别的部分加在了上传音频的步骤中，在该步骤中进行了 Fast-Whisper 模型的调用，进行了音频转文字的操作，加入该模块后的流程如下图 4-12 所示。




图 4-12 音频识别优化流程图

该项目将音频转文字的部分放在了上传音频的时候，进行了一个数据预处理，在这部分调用 Fast-Whisper 进行音频转文字的操作，然后将结果生成 Prompt 一起交给了 LLM，这样就可以充分发挥模型本身的能力，起到一个非常好的效果。

4.4 视频伪造识别模块设计

该项目使用了 PyDeepFakeDet 是一个集成且可扩展的工具，专门用于检测深度伪造（Deepfake）视频。它由复旦视觉与学习实验室开发，旨在提供最先进的深度伪造检测模型。该工具采用多种深度学习技术，包括卷积神经网络（CNN）和 Transformer 模型，来实现高效

准确的深度伪造检测。

DeepFake（深度伪造）是英文“Deep Learning”和“Fake”的混成词，专指基于人工智能的人体图像合成技术。广义而言，是指通过使用深度学习算法（如生成对抗网络，GANs）生成、修改或合成逼真的图像、音频或视频内容，以假乱真的技术。这些内容通常涉及将一个人的脸部特征、声音或动作移植到另一个人身上，或者完全生成虚构的图像和视频。该模块的具体流程如下图 4-13 所示。




图 4-13 人脸伪造检测流程

4.4.1 模型训练流程

ResNet50 模型检测的主要流程如下：

- 1.输入处理：将输入视频帧或图像通过卷积层，提取低级别特征，如边缘和纹理。
- 2.卷积层：多个卷积层逐渐提取更高级别的特征，这些特征可以包括复杂的图案和结构。

3.残差块：每个残差块通过跳跃连接（shortcut connections）将输入直接传递到输出，减轻了梯度消失问题，使得网络可以更深。具体而言，残差块的输出是： $y = F(x, \{W_i\}) + x$ 其中， $F(x, \{W_i\})$ 表示卷积层的输出， x 是输入。

4.特征提取：通过多个残差块，逐步提取更加抽象和高级的特征，这些特征可以反映出人脸图像中的细微变化。

5.全局平均池化：将最后一层的特征图通过全局平均池化层转换成固定长度的特征向量，减少参数数量，防止过拟合。

6.分类层：将特征向量输入全连接层进行分类，输出是伪造与否的概率分布。




图 4-14 ResNet50 模型流程图

4.4.2 人脸伪造风险点摘要热力图设计

Grad-Cam 是通过基于梯度的定位对深度网络进行可视觉解释。它使用流入最终卷积层的任何目标类别的梯度来生成粗略定位图，突出显示图像中的重要区域。

在深度学习模型的应用中，尤其是在人脸识别和伪造检测领域，理解模型的决策过程变得越来越重要。Grad-CAM（Gradient-weighted ClassActivation Mapping）是一种用于可视化卷积神经网络（CNN）内部工作机制的方法。它能够生成热力图，展示模型在进行分类时关注的图像区域，帮助我们解释模型的行为。

Grad-CAM 代表梯度加权类激活映射。这是一种用于深度学习的技术，特别是卷积神经网络（CNN），用于了解输入图像的哪些区域对于网络对特定类别的预测很重要。Grad-CAM 是一种技术，它保留了深度模型的架构，同时在不影响准确性的情况下提供可解释性。Grad-CAM 被强调为一种类判别定位技术，它为基于 CNN 的网络生成视觉解释，而无需更改架构或重新训练。

本项目中的 Grad-CAM 功能旨在可视化人脸识别模型在检测伪造区域时的关注点。通过生成热力图，我们可以直观地看到模型在判断伪造时重点关注的图像部分，从而更好地理解 and 验证模型的可靠性。

工作原理如下：

- **图像输入与模型推理：**将输入图像传入预训练模型，获取分类结果。
- **特征图和梯度捕获：**通过前向和后向钩子函数捕获目标卷积层的特征图和梯度。
- **计算 Grad-CAM：**利用捕获的特征图和梯度，计算每个像素点的权重并生成热力图。
- **热力图可视化：**将生成的热力图叠加到原始图像上，突出显示模型关注的区域。

可视化流程如下：

1. 输入：提供一张图像和一个感兴趣的类别（例如：tiger cat）。输入图像可以是任何适用于模型的图像格式，同时指定需要解释的目标类别，以便生成针对该类别的激活图。
2. 前向传播：将预处理后的图像输入预训练的卷积神经网络（CNN）模型，进行前向传播。通过模型的各层卷积操作，最终在模型的全连接层（softmax 层之前）得到特定任务的各种类别分数 y 。这些分数代表模型对每个类别的预测信心。
3. 设置梯度：对输出的类别分数进行梯度设置。将感兴趣的类别（例如：tiger cat）的梯度设置为 1，而其他所有类别的梯度设置为 0。这样可以确保在进行反向传播时，只计算与目标类别相关的梯度信息。
4. 反向传播：将设置好梯度的类别分数 y_c ，反向传播至卷积特征图。通过模型的反向传播过程，捕获目标卷积层的梯度信息。这些梯

度表示该层输出特征图对目标类别的影响程度。结合卷积特征图，计算得到初步的梯度激活映射（CAM），生成粗糙的热力图。

5. 生成高分辨率 Grad-CAM 图像：将初步生成的热力图与反向传播得到的梯度进行点乘。通过对特征图通道的加权求和，生成高分辨率的 Grad-CAM 可视化图。热力图经过归一化处理，并调整到与原始图像相同的大小。最后，将生成的热力图叠加到原始图像上，形成最终的可视化结果。

结果展示：




图 4-15 人脸伪造结果展示热力图

输出是一张热力图叠加在原始图像上的可视化图像。热力图中的高亮区域（通常为红色）表示模型在做出决策时最为关注的部分。这个方法非常适合用于人脸识别伪造检测，因为它能够直观地显示模型在判断伪造时关注的图像区域，从而帮助我们理解模型的决策过程并验证模型的可靠性。

4.4.3 视频伪造识别智能体 Prompt 封装流程

视频伪造识别智能体同音频识别智能体的封装流程较为类似，具体的思维链如下所示：

<|user|>

用户上传视频文件，并询问是否是伪造人脸视频

<|assistant|>

思考应该做什么

<|assistant|>调用工具名称(该模块为 video_function)

```

... python
tool_call(调用工具的参数)
...
<|observation|>
工具返回结果
<|assistant|>
(获取视频是否为伪造视频)返回给用户结果

```

首先在上传视频文件的部分需要做一个预处理，也是和音频部分考虑的一样，为了考虑到响应时间的问题，我们对视频文件做了一个预处理，首先是提取视频帧，然后生成图片，最后对图片提取人脸信息，最后在调用 Video_function 时，直接根据权重参数和人脸信息进行一个判别并返回结果给大语言模型进行一个回复操作，该模块的具体流程图如下图 4-16 所示。




图 4-16 伪造人脸识别流程图

5 技术实现

5.1 数据收集与预处理

1. 文本模块

对于文本模块的数据选择，我们重点收集了真实短信和诈骗短信，确保数据的多样性和真实性：

◆数据收集：

- **真实短信**：从多种来源收集了 30000 条真实短信，包括日常通信、商业通知等，涵盖多种常见场景。
- **诈骗短信**：从多个渠道获取了 14000 条已确认的诈骗短信，涵盖常见的诈骗手法和内容，如钓鱼链接、假冒客服等。

◆数据预处理：

- **去重与去噪**：去除重复和噪声数据，确保数据集质量和代表性。
- **文本清洗**：进行分词、去停用词、标注等处理，确保文本格式规范，便于模型输入。
- **数据标注**：为每条短信标注其类别（真实短信或诈骗短信），构建高质量的标注数据集。

2. 音频模块

◆ 数据收集：

使用了 Fake-or-Real(FoR)数据集，该数据集包含超过 195,000 个真实人类和合成的计算机生成的语音样本。这个数据集可以用于训练分类器以更好地识别假语音。数据集包含来自 Deep Voice 3 和 Google Wavenet TTS 以及各种人类声音录音的信息。

该数据集有四种不同的版本：(1) for-original, (2) for-norm, (3) for-2sec, (4) for-rerec。

- **for-original**：包含从语音源中提取后未做任何修改的文件。
- **for-norm**：包含与第一种版本相同的文件，但在采样率、音量和各种通道上进行了标准化，以实现性别和类别的平衡。
- **for-2sec**：基于 for-norm 版本，但文件被截断到 2 秒钟长度。
- **for-rerec**：是 for-2sec 版本的重新录制版，模拟攻击者通过语音通道传输语音。

除此以外为了增加该模型在中文音频上的识别率，我们还增加了 CFAD 中文数据，CFAD 数据集的每个版本(干净版本、噪声版本和编解码版本)中，训练集中有 138400 个话语，开发集中有 14400 个话语，可见测试集中有 42000 个话语，未见测试集中有 21000 个话语。

◆数据预处理：

数据集存在重复文件、0 位文件和音频信号中的不同比特率问题，这些问题会对机器学习模型的训练和性能产生负面影响。

a) 预处理步骤包括：

b) 删除重复和 0 位文件。

c) 将比特率标准化，对少于 16,000 样本的音频波形进行零填充，以符合 TensorFlow 音频信号处理库的操作比特率。

d) 使用标准缩放器对数据进行归一化，以便于模型训练。

3. 视频模块

◆数据收集：

在人工智能领域，深度伪造（DeepFake）技术的快速发展带来了新的挑战和机遇。为了推动这一领域的研究，Yuezun Li 等人引入了 Celeb-DF, 一个大规模且极具挑战性的深度伪造检测数据集。这个数据集包含了 590 个原始名人视频，以及从这些视频中合成的 5639 个虚假视频。Celeb-DF 的目标是为学术界和业界提供一个基准，以改进现有的深度伪造检测方法。

Celeb-DF 数据集的独特之处在于其广泛性和多样性，包括不同年龄、种族和性别的主题。这使得该数据集成为测试和评估深度伪造检测算法性能的理想平台。与以往的数据集相比（如 UADFV、DeepFake-TIMIT 和 FaceForensics++），Celeb-DF 提供了更复杂、更逼真的伪造样本。此外，Celeb-DF 还提供了对当前最优检测方法的平均 AUC 性能的评估，展示了在该数据集上检测真实与伪造视频的难度。如下图 5-1 所示：




图 5-1 SOTA 检测方法在每个数据集上的平均 AUC 性能

Celeb-DF 数据集的特点如下：

1. 规模大：总共包含超过 6000 个视频，提供了大量训练和测试素材。
2. 多样化：涵盖各种年龄段、种族和性别的人群，模拟真实世界中的深度伪造场景。
3. 高质量：合成视频质量高，挑战现有检测算法的极限。
4. 公开透明：提供详细的研究论文，透明度高，易于理解。
5. 隐私保护：遵循严格的使用条款，尊重个人隐私。

Celeb-DF 数据集在发布后得到了广泛的关注和应用。研究人员利用该数据集对现有的深度伪造检测方法和算法进行了全面评估，并发现该数据集确实给 DeepFake 检测带来了新的挑战与提升空间。实验结果表明，Celeb-DF 数据集上的深度伪造视频对多种检测方法都产生了显著的影响，使得检测算法的性能有所下降。总之，CelebDF 数据集为深度伪造检测领域提供了重要的资源，并且其高质量和广泛的覆盖范围使其成为研究和开发新检测技术的理想选择。

◆数据预处理：

1. 划分数据集

首先，从 image_list.txt 文件中读取数据，将每行数据存储在一个列表中。然后，将该列表中的数据随机打乱，以确保数据的顺序是随机的。接下来，计算出训练集、验证集和测试集的划分索引。具体的划分比例是 8:1:1，即 80%的数据用于训练，10%的数据用于验证，10%的数据用于测试。

根据计算的索引，将数据集划分为三个部分：训练集、验证集和

测试集。然后，将训练集的数据写入一个名为 `train.txt` 的文件中，将验证集的数据写入一个名为 `val.txt` 的文件中，将测试集的数据写入一个名为 `test.txt` 的文件中。最终，三个新的文件分别包含了训练集、验证集和测试集的数据。整个过程完成后，会输出一条消息，表示数据集已经成功拆分并写入相应的文件中。

2. 抽取视频帧

视频帧抽取模块的主要功能是从视频文件中提取指定数量的帧，并将这些帧保存到指定目录。模块设计采用多进程方式并行处理多个视频文件，从而大幅提高处理效率。

首先，视频帧抽取模块需要读取包含视频文件路径列表。这些路径通常存储在一个文本文件中，每个路径对应一个待处理的视频文件。模块会从指定的文本文件中读取这些路径，生成待处理视频的列表。

其次，模块会根据视频文件的目录结构，在目标保存目录中创建对应的目录结构，以便存储提取的图像帧。这样做可以保持源视频目录结构与目标图像帧保存目录结构的一致性，便于管理和检索。

在多进程处理方面，模块会将视频文件列表随机分配给多个进程，每个进程处理一部分视频文件。每个进程会读取其分配到的视频文件，并将视频转换为图像帧。帧的数量由参数指定，通常从视频中均匀抽取。这样可以充分利用多核 CPU 的性能，提高处理速度。

处理过程中，模块会对每个视频文件进行视频转图像帧的操作。首先，打开视频并获取总帧数。然后，计算抽取帧的间隔，确保均匀抽取指定数量的帧。最后，将抽取到的帧保存为图像文件，并记录图像文件的相对路径。

所有进程完成处理后，模块会将每个进程的输出合并，生成一个包含所有图像帧路径的列表文件。这个列表文件将用于后续的伪造识别分析。处理过程中，模块会定期打印当前进程的处理进度和时间估算，包括已处理视频数量、总视频数量、已用时间和预计剩余时间。这有助于监控处理进度和优化处理流程。

视频帧抽取是人脸伪造识别系统中的关键步骤。通过合理设计和优化该模块，可以显著提高整个系统的处理效率和识别精度。本模块采用多进程并行处理技术，从视频文件中均匀抽取帧，并保存这些帧

供后续分析使用，为系统的高效稳定运行奠定了基础。

3. 提取人脸图片

人脸提取流程是人脸伪造识别任务中的关键前处理步骤。这个过程始于加载预训练的 **RetinaFace** 模型，该模型基于 **ResNet50** 架构，经过优化以实现高效准确的人脸检测。系统首先设置输入目录和输出目录，分别用于存放原始图像和保存提取的人脸图像。

在处理每张图像时，系统首先将其读取并转换为 **RGB** 颜色空间，确保与模型的输入要求一致。随后，使用 **RetinaFace** 模型对预处理后的图像进行人脸检测。模型会输出检测到的人脸位置和置信度。如果未检测到人脸，系统会标记该图像并可能保存用于后续分析。对于成功检测到人脸的图像，系统会进行进一步处理。

接下来，系统计算一个扩展边界框，以确保捕获完整的人脸区域。这个扩展边界框通常比原始检测框略大，目的是包含更多的面部特征和上下文信息，这对于后续的伪造识别任务很有帮助。使用计算得到的边界框，系统从原始图像中裁剪出人脸区域。裁剪后的人脸图像被保存到指定的输出目录，文件名通常与原始图像相关联以便于追踪。

为了提高处理大量图像的效率，系统采用了多进程处理方法。首先，将待处理的图像列表均匀分配给多个处理器核心。每个核心独立运行人脸检测和提取过程，处理分配给它的图像子集。这种并行处理方法显著提高了整体的处理速度，特别是在处理大规模数据集时。所有进程完成后，系统收集并合并各个进程的处理结果。

在整个处理过程中，系统会定期输出进度报告，包括已处理的图像数量、耗时和预估剩余时间。这不仅有助于监控处理进度，还能及时发现潜在的问题。对于处理过程中遇到的异常，系统会记录错误信息并继续处理其他图像，确保整体流程不会因单个图像的问题而中断。这种错误处理机制增强了系统的鲁棒性，使其能够处理各种复杂的实际场景。

处理完成后，系统会生成一个包含所有成功提取的人脸图像的目录，以及一个更新后的图像列表，记录了成功提取人脸的图像路径。这些输出为后续的人脸伪造识别任务提供了必要的数据库。通过这个高效且鲁棒的人脸提取流程，我们能够从大量原始图像或视频帧中

提取出高质量的人脸图像，为后续的伪造识别分析奠定坚实的基础。

这个流程的设计充分考虑了处理效率、准确性和异常处理，使其能够适应各种复杂的实际应用场景，从而为人脸伪造识别任务提供可靠的数据支持。

5.2 模型选择与训练

1. 文本模块

文本模型也就是大语言模型选用的是 DeepfakeChat。该模型是由 ChatGLM3-6B 进行监督微调所训练出来的短信诈骗风险模型，ChatGLM3 是智谱 AI 和清华大学 KEG 实验室联合发布的对话预训练模型。ChatGLM3-6B 是 ChatGLM3 系列中的开源模型，在保留了前两代模型对话流畅、部署门槛低等众多优秀特性的基础上，ChatGLM3-6B 引入了如下特性：

更强大的基础模型：ChatGLM3-6B 的基础模型 ChatGLM3-6B-Base 采用了更多样的训练数据、更充分的训练步数和更合理的训练策略。在语义、数学、推理、代码、知识等不同角度的数据集上测评显示，ChatGLM3-6B-Base 具有在 10B 以下的基础模型中最强的性能。

更完整的功能支持：ChatGLM3-6B 采用了全新设计的 Prompt 格式，除正常的多轮对话外。同时原生支持工具调用（Function Call）、代码执行（Code Interpreter）和 Agent 任务等复杂场景。

更全面的开源序列：除了对话模型 ChatGLM3-6B 外，还开源了基础模型 ChatGLM3-6B-Base、长文本对话模型 ChatGLM3-6B-32K 和进一步强化了对于长文本理解能力的 ChatGLM3-6B-128K。

DeepfakeChat 在进行监督微调后，在短信诈骗识别任务中得到了明显的提升，在我们所构造的人工标注数据集中，该模型对于诈骗风险识别的准确率达到了 98.5%。

2. 音频模块

在音频处理中我们选择了传统的机器学习模型支持向量机（SVM），在该模块中，我们重点关注在特征选择方面吗，我们最终选择了 MFCC 特征，也就是梅尔频率倒谱系数，它的优势在于两个方面：该特征通过使用对数函数和梅尔滤波器模拟人类听觉系统。并且应用三角带通滤波器将频率信息转换为类似人类感知的形式。

特征提取的过程如下：

- 1) 对音频信号进行初步处理后，从每个声波帧生成一组表示 MFCC 的向量。
- 2) 使用梅尔频率倒谱系数和短时傅里叶变换 (STFT)，将时域信号转换为时频域信号。

本研究测试了多种机器学习模型，包括支持向量机 (SVM)、梯度提升模型 (XGB) 和多层感知机 (MLP)。这些模型在不同的子数据集上进行了训练和测试，最终显示支持向量机在实验结果中表现好，并且在 ASVspoof2021 的数据集中达到了 99.23% 的正确率。

3. 视频模块

在人脸伪造识别模块，我们选择了 ResNet50 模型作为人脸伪造检测的主要模型。ResNet50 的深度使其能够提取到非常细致和高级的特征。人脸伪造通常涉及细微的像素级修改，这些修改需要深度网络来捕捉和识别。ResNet50 的 50 层结构使其能够逐层提取和组合低级和高级特征，从而更好地检测伪造痕迹。

ResNet50 在大规模数据集（如 ImageNet）上进行预训练，这意味着它已经学会了许多基本的图像特征。这些预训练的权重可以作为 deepfake 检测任务的良好起点，通过迁移学习可以快速适应新的任务，从而提高训练效率和性能。ResNet50 在各种计算机视觉任务中表现出色，具有良好的鲁棒性和泛化能力。对于人脸伪造检测，这意味着模型能够在不同类型的伪造技术和不同的数据集上保持较高准确性。

ResNet50 模型检测的主要流程如下：

1. 输入处理：将输入的视频帧或图像进行预处理，包括调整图像大小、归一化处理等。预处理后的图像数据通过第一层卷积层，提取出低级特征，如边缘和纹理。这一步骤确保输入数据在网络中的表现更好，并且使特征提取过程更有效。

2. 卷积层：多个卷积层逐步提取更高级别的特征。初始层提取简单的几何形状和纹理，而更深层的卷积层则能够识别复杂的图案和结构，如人脸的局部特征。每个卷积层后通常伴随着批归一化和激活函数（如 ReLU），以增强网络的学习能力和稳定性。

3. 残差块：每个残差块通过跳跃连接（shortcut connections）将输

入直接传递到输出，减轻了梯度消失问题，使得网络可以更深。具体而言，残差块的输出为 $y = F(x, \{W_i\}) + x$ ， $F(x, \{W_i\})$ 表示卷积层的输出， x 是输入。跳跃连接确保梯度可以有效地传递回前面的层，从而优化深层网络的训练效果。

4.特征提取：通过多个残差块，逐步提取更加抽象和高级的特征。这些特征能够捕捉到人脸图像中的细微变化，包括微小的伪造痕迹、光照变化、和细节的扭曲。这些高级特征是区分真实和伪造图像的关键。

5.全局平均池化：在网络的最后一层卷积层之后，使用全局平均池化层将特征图转换成固定长度的特征向量。全局平均池化通过对整个特征图求平均，减少了参数数量，防止过拟合，并且保持了重要的全局信息。这一步骤还有效地降低了模型的复杂性，提升了模型的泛化能力。

6.分类层：将全局平均池化层生成的特征向量输入到全连接层进行分类。全连接层通过一系列权重和偏置的线性组合，将特征向量映射到输出空间。最后，使用 **Softmax** 函数将输出转化为伪造与否的概率分布。网络输出两个概率值，分别表示图像为真实和伪造的概率，取概率最大的类别作为最终的分类结果。

7.输出和评估：网络输出的概率分布用于确定输入图像是否为伪造。通过与真实标签对比，可以计算分类的准确性、AUC 等指标，评估模型的性能。这些评估指标帮助我们了解模型的实际检测能力，并为进一步优化提供依据。

总结来说，选择 ResNet50 作为人脸伪造识别的模型，是因为它结合了深度网络的强大特征提取能力、残差连接的有效训练机制、预训练模型的高效利用、以及其在复杂视觉任务中的优异表现和广泛支持。这些因素共同使其成为一个理想的选择，用于检测和识别人脸伪造内容。

5.3 系统性能分析

1. 文本模块

在文本模块我们使用了原模型 ChatGLM3-6b 作为对比试验,实验结果显示我们微调后的模型 DeepfakeChat 在文本诈骗识别中的提

升了很大，准确率达到 98.58%，精确性达到了 99.05%，召回率达到了 99.32%，F1 分数达到了 99.18%。

实验设置

硬件配置：

GPU：NVIDIA GeForce RTX 4090

内存：128 GB

存储：2 TB SSD

数据集：

本实验选择了 1000 条随机的诈骗短信和非诈骗短信作为我们的实验数据，并设置了模型回答的 prompt，通过返回 true 和 false 来表示是否是诈骗短信。

实验结果：

表 1 ChatGLM3 原始模型实验结果

度量标准	值
准确率（Accuracy）	89.1%
精确率（Precision）	98.7%
召回率（Recall）	88.5%
F1 分数	0.933
平均运行时间	0.3810 秒
成功预测数	1000/1000

表 2 DeepfakeChat 模型实验结果

度量标准	值
准确率（Accuracy）	98.5%
精确率（Precision）	99.1%
召回率（Recall）	99.3%
F1 分数	0.991
平均运行时间	0.2763 秒
成功预测数	1000/1000

经过对比试验发现，微调后的模型在识别准确率上提升了接近 10 个百分点，在精确率、召回率、F1 分数等指标上都有所提升，并且在平均运行时间上也要更快，这一方面也说明了模型的诈骗风险推理能力有了很大的提高。

两个模型的实验对照图如图 5-2 所示：




图 5-2 ChatGLM3 与 DeepfakeChat 在诈骗短信识别性能对比图

2. 音频模块

音频模块测试了多种机器学习模型，包括支持向量机（SVM）、梯度提升模型（XGB）和多层感知机（MLP）。这些模型在不同的子数据集上进行了训练和测试。

实验设置

硬件配置：

GPU：NVIDIA GeForce RTX 4090

内存：128 GB

存储：2 TB SSD

数据集：

使用了 Fake-or-Real(FoR)数据集，该数据集包含超过 195,000 个真实人类和合成的计算机生成的语音样本。这个数据集可以用于训练分类器以更好地识别假语音。数据集包含来自 Deep Voice 3 和 Google Wavenet TTS 以及各种人类声音录音的信息。

该数据集有四种不同的版本：(1) for-original, (2) for-norm, (3) for-2sec, (4) for-rerec。

- **for-original:** 包含从语音源中提取后未做任何修改的文件。
- **for-norm:** 包含与第一种版本相同的文件，但在采样率、音量和各种通道上进行了标准化，以实现性别和类别的平衡。
- **for-2sec:** 基于 for-norm 版本，但文件被截断到 2 秒钟的长

度。

• **for-rerec:** 是 for-2sec 版本的重新录制版，模拟攻击者通过语音通道传输语音。

实验结果：

表 3 机器学习模型的精度比较

Models	for-2sec	for-norm	for-rerec
SVM	97.57	71.54	98.83
MLP Classifier	94.69	86.82	98.79
Decision Tree	87.13	62.16	88.28
Extra Tree Classifier	94.61	91.46	96.87
Gaussian Naive Bayes	88.20	81.81	81.91
Ada Boost	90.23	88.40	87.67
Gradient Boosting	94.30	92.63	93.51
XGBoost	94.52	92.60	93.40
Linear Discriminant Analysis	89.50	91.35	87.56
Quadratic Discriminant Analysis	96.13	61.36	96.91

表 4 使用机器学习模型对噪声音频信号进行精度比较。

Models	for-2sec	for-norm	for-rerec
SVM	99.59	75.21	98.83
MLP Classifier	99.49	89.22	98.66
Decision Tree	87.52	65.10	82.12
Extra Tree Classifier	97.91	90.19	96.25
Logistic Regression	87.53	86.25	88.00
Gaussian Naive Bayes	77.97	80.15	82.14
Ada Boost	85.28	89.35	83.89
Gradient Boosting	92.25	93.50	88.86
XGBoost	92.22	94.25	88.92
Linear Discriminant Analysis	87.05	90.52	85.88
Quadratic Discriminant Analysis	96.22	65.15	95.59




图 5-3 SVM 模型训练的准确率和损失图

综合以上实验，最后该系统选择了 SVM 作为音频部分的模型。训练时的准确率和损失如图 5-3 所示。

3. 视频模块

实验设置

硬件配置：

GPU: NVIDIA GeForce RTX 4090

内存: 128 GB

存储: 2 TB SSD

数据集：

本实验使用了一个包含真实和伪造人脸视频的定制数据集。为了提高模型的泛化能力，我们对数据进行了以下预处理和增强操作：

- 图像尺寸：所有输入图像均被调整为 380x380 像素。
- 训练数据增强：将图像大小调整为 380x380 像素；以 50% 的概率对图像进行水平翻转；使用均值为[0.5, 0.5, 0.5]和标准差为[0.5, 0.5, 0.5]对图像进行归一化。
- 测试数据增强：将图像大小调整为 380x380 像素；使用均值为[0.5, 0.5, 0.5]和标准差为[0.5, 0.5, 0.5]对图像进行归一化。

模型设置：

为了高效加载和处理数据，我们配置了数据加载器如下：

- 批量大小（Batch Size）：32
- 工作线程数（Num Workers）：4

本实验采用了预训练的 ResNet50 模型，该模型在 ImageNet 数据集上进行了预训练，并在本任务中进行了微调。模型的配置如下：

- 模型名称：ResNet50
- 预训练权重：ImageNet
- 输出类别数：2（真实和伪造）

为了优化模型，我们选择了 Adam 优化器，其配置如下：

- 优化方法：Adam
- 基础学习率：0.0004
- Beta 参数： [0.9, 0.999]
- Epsilon: 0.00000001

- 权重衰减: 0.000001

训练过程包括以下步骤:

1. **数据加载:** 将预处理后的人脸图像数据加载到内存中, 划分为训练集、验证集和测试集。使用 **DataLoader** 进行批量加载。
2. **模型初始化:** 初始化模型参数, 并选择优化器 (**Adam**) 和损失函数 (交叉熵损失)。
3. **前向传播:** 将输入数据传递给模型, 计算每个批次的预测结果。
4. **损失计算:** 使用交叉熵损失函数计算预测结果与真实标签之间的误差。
5. **反向传播:** 计算损失函数对模型参数梯度, 并使用优化器更新模型参数。
6. **模型评估:** 在每个 **epoch** 结束时, 使用验证集评估模型性能, 记录准确率、AUC 和损失值。
7. **模型保存:** 根据验证集性能, 保存最佳模型权重。

评价指标:

在训练过程中, 我们使用以下评价指标来评估模型性能:

- **准确率 (Accuracy):** 正确预测的样本占总样本的比例。
- **AUC (Area Under Curve):** ROC 曲线下面积, 衡量分类器区分能力。
- **损失值 (Loss):** 交叉熵损失函数计算的预测误差。

实验结果:

表 5 人脸伪造识别实验结果

度量标准	值
准确率 (Acc@1)	99.940%
AUC	1.000
损失值 (Loss)	0.001
验证时间	9 秒
每次迭代时间	0.0438 秒
第 19 轮耗时	222.38 秒
平均轮次耗时	222.40 秒
中位数轮次耗时	222.37 秒
每次迭代平均时间	0.13 秒

实验结果显示, 模型在测试集上的表现极为优异, 准确率达到了

99.940%，AUC 为 1.000，损失值仅为 0.001。这表明模型在区分真实和伪造人脸方面非常准确。每次迭代平均耗时 0.0438 秒，总验证时间仅为 9 秒，表明模型的训练和验证效率较高。此外，单个 epoch 的平均耗时为 222.40 秒，显示出模型在整个训练过程中的稳定性。

通过以上数据可以看出，模型在测试集上的表现非常出色，准确率接近 100%，AUC 值达到 1，损失值非常低，表明模型能够有效区分真实和伪造人脸。同时，训练过程耗时相对较短，证明了模型的高效性。




图 5-4 ResNet50 模型训练和验证损失曲线

从图 5-4 中可以看出模型展现出了非常快的收敛速度。在前几个 epoch 中，无论是训练损失还是验证损失都有显著下降。特别是从第 1 个 epoch 到第 2 个 epoch，损失值急剧下降，这表明模型在初始阶段学习得非常快。整体来看，模型的学习效果非常好。训练损失从初始的 0.0322 迅速下降到 0.0002，验证损失从 0.031 下降到 0.001 左右。这表明模型能够有效地从训练数据中学习，并且学到的知识能够很好地泛化到验证集上。

值得注意的是，训练损失和验证损失的曲线非常接近，尤其是在后期阶段。这是一个非常好的迹象，表明模型没有明显的过拟合现象。如果存在严重的过拟合，我们通常会看到训练损失持续下降而验证损失在某个点后开始上升。在训练后期（大约从第 10 个 epoch 开始），损失值的下降变得非常缓慢，并且趋于稳定。这表明模型已经接近最

优状态，进一步的训练可能只会带来微小的改善。

总的来说，这个训练过程展现了一个非常成功的模型学习案例。模型快速收敛，没有明显的过拟合，并且在验证集上取得了很优秀的性能。这为后续的模式部署和应用奠定了坚实的基础。




图 5-5 ResNet50 模型训练过程中的准确率和 AUC 变化

如图 5-5 所示，实验展示了模型卓越的学习能力和效率。从首个训练轮次开始，模型就展现出了令人瞩目的性能，准确率达到 95.831%，AUC 高达 0.993。这个起点已经相当高，表明模型架构设计合理，初始化策略得当。更值得注意的是，模型在随后的几个 epoch 中表现出很好的学习速度。到第 4 个 epoch 时，准确率已上升至 99.562%，AUC 达到了理论上的最佳值 1.0。这种快速收敛的特性体现了模型强大的特征提取和学习能力。

模型在整个训练过程中展现出了卓越的稳定性和一致性。从第 4 个 epoch 开始，准确率始终保持在 99% 以上的高位，仅在个别 epoch 出现微小波动。这些细微的起伏可能是由于随机批次采样或学习率调整等因素引起，但并不影响整体性能。特别值得一提的是 AUC 指标的表现，自第 4 个 epoch 达到 1.0 后，便在后续的所有 epoch 中保持不变。这一现象充分说明了模型在类别区分方面达到了近乎完美的水平，能够在各种不同的分类阈值下都保持最优的性能。这种持续的高水平表现不仅反映了模型的鲁棒性，也说明了训练过程中使用的优化

策略非常有效，成功地将模型引导至一个稳定的最优解。

从整体训练曲线来看，这个模型呈现出一种"高原"型的学习模式。在快速上升阶段后，性能指标进入了一个高位平稳期。这种模式通常出现在模型已经充分学习了数据集中的所有有用信息，达到了任务允许的性能上限。在第 11 个 epoch 之后，准确率多次触及 99.95% 以上，这几乎是完美的分类结果。如此高的准确率，结合始终保持在 1.0 的 AUC 值，强烈暗示了该模型在这个特定任务上可能已经达到了理论上的最佳性能。这不仅体现了模型本身的优越性，也反映出数据集可能存在明确的、易于学习的模式。同时，这种持续的高性能也提示我们，延长训练时间可能不会带来显著的额外收益，相反，可以考虑在较早的阶段（如第 10 到第 12 个 epoch 左右）就停止训练，以优化计算资源的使用。

6. 成果展示

6.1 文本智能体




图 6-1 文本智能体界面

诈骗文本分析模块是“基于大模型的多模态诈骗内容识别系统”中的一个关键组件，旨在通过分析用户输入的文本内容识别潜在的诈骗信息。该模块提供实时的文本分析反馈，并通过关键词云图直观展示诈骗风险。

页面布局分为三个主要部分：聊天框、诈骗文本分析结果、诈骗风险关键词云图。

1. 聊天框：用户可以在聊天框中输入文本，该文本将被提交用于诈骗分析。用户输入的文本和系统返回的结果会在对话框中展示，方便用户查看和追溯历史记录。

2. 诈骗文本分析结果：系统会对用户输入的文本进行详尽分析，并即时返回分析结果，明确指出该文本是否存在诈骗风险及其背后的具体原因。分析说明部分将详细阐述系统如何根据文本内容作出判断，而风险等级则直观反映了文本潜在的诈骗威胁程度。此外，系统还会具体列出文本中那些可能触发诈骗判定的关键特征，以使用户能够更清晰地识别并防范潜在的诈骗行为。

3. 诈骗风险关键词云图：根据用户输入的文本，系统生成并展示一个关键词云图，显示与诈骗相关的高频词汇，帮助用户直观了解文本中存在的诈骗风险。每次用户输入新的文本进行分析时，关键词云图会动态更新，反映最新的分析结果。




图 6-2 文本智能体分析文本界面

如图所示，用户输入了一段描述内容：“手头紧找平安直通货最快天放款月息最低 DIGIT 大平台有保证贷款成功送万个万里通积分详情点击 URLdfgePLACE 平”系统分析后返回以下反馈：

分析结果：系统提示该文本存在潜在的诈骗风险，并给出了详细的原因，包括促销活动、投资机会、人际网络、URL 钓鱼平台、假冒公司等特征。

关键词云图：系统生成的关键词云图显示“直通”、“平安”、“最快”、

“月息”等高频词汇，表明这些词汇在文本中与诈骗内容高度相关。

通过上述功能，该模块能够帮助用户识别和预防潜在的诈骗信息，提高安全防范意识。

6.2 音频智能体




图 6-3 音频智能体界面

诈骗音频分析模块旨在检测并识别音频内容中潜在的诈骗信息。通过多模态技术，该模块利用大模型对输入音频进行深入分析，提取并识别其中的诈骗特征。页面布局分为三个主要部分：文本和音频上传区域、梅尔频率倒谱系数（MFCC）特征图、音频波形图。

1. 音频上传与处理：用户通过页面底部的上传按钮选择并上传待分析的音频文件。上传的音频文件将被系统处理，包括去噪、归一化等预处理步骤，以确保后续分析的准确性。使用高级语音识别技术将音频内容转化为文本，便于后续的自然语言处理分析。

2. 梅尔频率倒谱系数（MFCC）特征图：生成音频的 MFCC 特征图，展示音频频率随时间变化的情况。这些特征有助于识别音频中的语音模式和特征。

3. 音频波形图：生成音频的波形图，展示音频信号的时间域特征，帮助用户直观了解音频的整体结构和强度变化。




图 6-4 音频智能体分析界面

如上图所示，用户上传了一个名为“longaudio.wav”的音频，并询问“请分析该音频是否被篡改过，并根据内容判断是否含有诈骗信息？”系统通过分析返回以下结果：

文本反馈：系统将自动生成一份详细的诈骗风险报告，包括音频的基本信息、初步判断结果、详细分析内容以及建议的防范措施。报告中会明确指出音频中发现的诈骗信息点，并给出相应的解释和依据。用户可以根据报告中的信息，采取相应的措施来避免或应对潜在的诈骗风险。

诈骗音频分析模块结合了多模态技术和大模型能力，通过音频处理、语音识别、自然语言处理和特征提取等多种手段，全面分析并识别音频中的诈骗信息，为用户提供准确、高效的诈骗内容识别服务。

6.3 视频智能体



图 6-5 视频智能体界面

视频人脸伪造分析模块是“基于大模型的多模态诈骗内容识别系统”中的一个重要组成部分，主要用于检测和分析用户上传的视频是否包含伪造的人脸信息（如 Deepfake）。该模块通过先进的深度学习模型，对视频进行分析并提供详细的伪造检测结果。页面布局分为三个主要部分：文本和视频上传区域、人脸伪造区域显示、视频伪造概率曲线。

1. 视频上传与处理：用户通过页面底部的上传按钮选择并上传待分析的视频文件。支持多种视频格式（如 MP4、AVI、MOV 等）。系统接收到视频文件后，首先进行格式验证和完整性检查，确保视频文件可用且未损坏。然后，系统对视频进行预处理，包括帧提取、分辨率调整等，以便后续的伪造检测分析。

2. 视频伪造分析：用户可以在聊天框中输入提示语，大语言模型会根据用户上传的聊天内容进行分析，判断是否调用视频伪造识别函数对视频进行分析，并且返回分析的结果。

3. 人脸伪造区域显示：页面右上角显示了视频分析结果的人脸伪造区域热图。该热图通过 Grad-CAM 技术生成，利用颜色变化（如红色表示高风险区域）直观展示模型在检测伪造时关注的图像区域。用户可以通过热图快速定位和识别视频中的可疑伪造部分，从而更有效地进行进一步分析和验证。

4. 伪造概率曲线：系统对视频进行抽帧分析，计算每一帧的伪造概率。综合分析视频帧的伪造概率，评估视频是否伪造。页面右下角的伪造概率曲线图横轴表示视频帧序号，纵轴表示伪造概率。曲线图可以帮助用户了解视频中伪造风险随时间的变化情况。




图 6-6 视频智能体分析界面

如上图 6-6 所示，用户上传了一个视频，并询问“该视频是伪造的吗？”系统通过分析返回以下结果：

文本反馈：根据 API 调用结果，这个视频被确认为伪造的人脸视频。

热力图展示：热力图显示了视频中人脸区域的伪造风险，热力图中红色区域代表伪造风险较高的部分，在此视频中，右眼区域显示为红色，提示此处伪造可能性较大。

概率曲线图：概率曲线图显示整个视频各帧的伪造概率，在整个视频的分析过程中，抽取的每一帧的伪造概率均保持在 100%，这表明系统检测到的视频每一帧都存在伪造的迹象。通过该概率曲线图，用户可以直观地看到视频中所有帧的伪造概率保持一致，进一步支持系统的伪造判定结果。

视频人脸伪造分析模块通过高效的人脸检测、伪造特征提取、伪造判断与风险评估以及结果反馈与可视化等流程，实现了对视频中人脸伪造行为的精准识别与评估。该模块不仅提高了诈骗内容识别的准

确性和效率，也为打击网络诈骗行为提供了有力的技术支持。

6.4 智能分析模块

基于大模型的多模态诈骗内容识别系统

文本智能体

音频智能体

视频智能体

智能分析

风险态势分析平台

标题

请输入标题

搜索

重置

新增

ID	标题	内容	类型	诈骗类型	地区	结果	操作
1	可疑短信警告	收到一条声称来自中奖短信，要求提供银行卡信息。	文本	短信诈骗	北京市	已诈骗	编辑删除
2	虚假投资理财	微信中收到高回报率的投资项目，要求立即汇款。	音频	电话诈骗	上海市	未检测	编辑删除新增
3	正常广告邮件	某知名品牌发送的新品促销邮件。	文本	无	广东省	无风险	编辑删除
4	虚假贷款广告	网页上发布无抵押、低利率贷款，要求先缴手续费。	文本	贷款诈骗	广东省	已诈骗	编辑删除
5	正常数据备份	某电商平台发送的账户余额变动通知。	音频	无	浙江省	无风险	编辑删除
6	可疑中奖提醒	视频中声称用户已中大奖，需要缴纳税费才能领奖。	视频	中奖诈骗	四川省	未检测	编辑删除新增
7	正常网购订单确认	某电商平台发送的订单确认短信。	文本	无	湖北省	无风险	编辑删除
8	可疑招聘电话	声称提供高薪工作，要求先缴纳培训费或押金。	音频	招聘诈骗	江苏省	已诈骗	编辑删除
9	银行App更新通知	某银行App发送的更新提醒短信。	文本	无	重庆市	无风险	编辑删除
10	可疑短信信息	在微信网站上发布虚假信息，骗取会员费和订费。	文本	短信诈骗	陕西省	未检测	编辑删除新增
11	正常公司内部通知	公司人事部门发送的员工福利政策更新通知。	文本	无	天津市	无风险	编辑删除
12	可疑股票推荐视频	制作感人的慈善视频，实际是设计骗局的。	视频	慈善诈骗	江苏省	已诈骗	编辑删除
13	正常医疗咨询	某三甲医院网站上进行医疗咨询服务。	音频	无	河南省	无风险	编辑删除
14	可疑彩票中奖电话	声称用户购买彩票中奖，要求支付手续费。	音频	彩票诈骗	山东省	已诈骗	编辑删除
15	正常游戏充值提醒	某知名游戏平台发送的充值成功确认短信。	文本	无	辽宁省	无风险	编辑删除
16	可疑租房信息	发布虚假房源信息，骗取定金或押金。	文本	租房诈骗	浙江省	未检测	编辑删除新增
17	正常工资条通知	公司财务部门发送的月度工资条邮件。	文本	无	福建省	无风险	编辑删除

图 6-7 智能分析管理平台

这是“基于大模型的多模态诈骗内容识别系统”的智能分析管理界面，它展示了系统对各种诈骗内容的自动分析和管理工作。页面顶部提供了搜索与过滤功能，用户可以在标题输入框中输入关键字来搜索特定的诈骗内容记录，点击搜索按钮后，系统会根据输入的标题关键字进行搜索。重置按钮可以清除当前的搜索条件，显示所有记录，而新增按钮则用于添加新的诈骗内容记录。

诈骗类型字段对诈骗手段进行了具体分类，如中奖诈骗、电话诈骗等，这些细化分类便于统计和分析。地区字段记录了诈骗内容涉及的地理区域，有助于识别地域性诈骗活动的特点。结果字段显示系统自动识别的结果，表明内容是否被判定为诈骗。具体结果可能是已诈骗、无风险或未检测。操作字段提供用户对每条记录进行进一步操作的选项，如编辑、删除或手动触发系统检测。

这个智能分析管理界面展示了系统的多模态数据处理能力，能够支持文本、音频和视频等多种类型的诈骗内容，综合分析多模态数据，提高识别的全面性和准确性。系统利用大模型技术对诈骗内容进行检测，并给出明确的判断结果，帮助用户评估和管理诈骗内容。同时，通过记录诈骗内容的地区信息，系统能够对不同地区的诈骗活动进行

分析和监控，提供地域性诈骗的预警和防范措施。

系统界面提供了丰富的用户交互功能，包括搜索、编辑、删除和手动检测，方便用户对诈骗内容进行管理和操作。通过这些功能，系统实现了高效识别、多模态支持和智能化管理，大大减少了人工干预，提高了管理效率。这些优势使得“基于大模型的多模态诈骗内容识别系统”在实际应用中具有重要意义，能够有效帮助用户识别和防范各类诈骗内容。

6.5 涉诈风险态势分析平台



图 6-8 涉诈风险态势分析平台

诈骗风险态势分析平台集成了先进的人工智能技术，特别是大模型与多模态数据处理能力，以实现对网络空间中复杂多变的诈骗内容的实时监测、分析与预警。大屏展示界面作为系统的核心视觉呈现，集成了丰富的图表与数据，为安全专家及管理人员提供直观、全面的诈骗风险态势分析。

全国涉诈风险地图:此图表以中国地图为背景，通过不同颜色或形状的标记展示全国范围内诈骗风险的分布情况。标记的颜色深浅或形状变化反映诈骗风险的高低，帮助用户快速识别高风险区域。

诈骗类型分布环形图:展示当前检测到的诈骗类型分布，如网络钓鱼、电话诈骗、短信诈骗、社交媒体诈骗等。各类型占比直观反映诈骗手法的多样性及主要威胁方向。

诈骗风险关键词云图:通过高效提取和可视化诈骗相关的核心词汇,揭示最新的诈骗话术和趋势。这种方法不仅能够快速识别潜在的诈骗风险,还能帮助分析和预测诈骗行为的变化,为防范措施的制定提供有力支持。

各模块识别准确率仪表盘:分别展示了平台在识别可疑文本方面的卓越能力,为涉诈文本监管提供有力支持;凸显了系统在甄别伪造音频方面的高效表现,为语音安全保障提供坚实基础;突出平台在识别数字伪造人脸方面的领先水平,为视频真实性验证提供可靠保障。

诈骗热点事件轮播图:自动识别并排序当前最突出的诈骗类型,通过动态展示最新的诈骗热点,帮助用户实时了解最紧迫的风险。这种轮播图不仅提供直观的诈骗事件概览,还能辅助制定针对性的防控策略,提升防范效率。通过及时更新和排序热点事件,轮播图支持快速响应和调整防控措施,以应对不断变化的诈骗趋势。

诈骗案例趋势图:通过多维度展示诈骗案例的演变趋势,提供深入的趋势分析和洞察。这种趋势图能够支持预测性分析,帮助识别潜在的诈骗模式,并为前瞻性的防控措施制定提供数据驱动的决策支持。通过对历史数据的综合分析,趋势图能够揭示诈骗手法的变化规律,助力制定更有效的预防策略和应对措施。

7. 实用性和应用前景

该系统具有非常好的实用性,大致可以从以下几点可以看出。

● 数据获取便捷程度:

该系统能够从多个渠道轻松获取数据,包括短信、音频录音和视频文件。通过与通信运营商、金融机构、电子商务平台等合作,系统获取的数据覆盖面广且具有高质量。自动化的数据收集和预处理工具能够实时更新和清理数据,确保数据的相关性和准确性。

● 风险感知的速度与效率:

系统具备强大的实时分析能力,能够快速处理和分析多模态数据。使用微调后的 DeepfakeChat 大语言模型,系统能够迅速识别文本中的诈骗信息,结合音频和视频分析模块,对多种类型的诈骗行为进行综合分析和识别。在检测到潜在诈骗行为时,系统能够即时发出预警,确保用户能在第一时间采取措施。

● 系统的易于部署:

系统设计采用模块化架构，支持灵活的部署方式。无论是本地部署以保证数据私密性，还是云端部署以提高扩展性，系统都能满足不同用户的需求。简洁直观的用户界面使得非技术用户也能轻松使用系统，降低了操作门槛。

该系统也具备非常好的应用前景：

- 1) 该系统可以帮助银行、保险公司等金融机构检测和防范欺诈交易和假冒客服等诈骗行为，保护客户资产安全。
- 2) 电信运营商可以利用系统监测和阻止诈骗电话和短信，为用户提供更安全的通信服务，减少诈骗引起的用户投诉。系统能够帮助电子商务平台识别虚假广告、伪造产品信息等诈骗行为，保障消费者权益，提升平台的信誉和公信力。
- 3) 政府和公共安全机构可以部署系统，监控和打击网络诈骗活动，维护社会秩序和安全。
- 4) 个人用户可以通过系统获得防诈骗提醒和保护措施，特别是对于易受骗的群体，如老年人和青少年，系统提供了有效的防护手段。
- 5) 该系统支持多语言和多模态数据处理，具备在全球市场的竞争力。它能够为跨国用户提供防诈骗服务，应对日益增多的国际性诈骗行为。